

# Reconocimiento de placas vehiculares con redes neuronales

*Víctor Camones*  
UPC (Universidad Peruana de  
Ciencias Aplicadas)  
Lima, Perú  
u201623394@upc.edu.pe

*Hillary Moscoso*  
UPC (Universidad Peruana de  
Ciencias Aplicadas)  
Lima, Perú  
u201716908@upc.edu.pe

*Sebastián Peralta*  
UPC (Universidad Peruana de  
Ciencias Aplicadas)  
Lima, Perú  
u201816030@upc.edu.pe

**Abstract**—A diario todas las comunidades o ciudades, para proveer un estilo de vida cómodo y tranquilo, requieren de sistemas o protocolos de seguridad ciudadana. En Perú, la inseguridad en las calles genera una constante preocupación para todos los habitantes. Por lo tanto, herramientas que faciliten que se ejerza la ley siempre serán beneficiosas para la población. Este paper propone utilizar un modelo de red neuronal pre entrenado (ResNet50), para aprovechar la estructura y conocimiento de la red y sobre ella entrenarla con nuestra data. De tal manera que, el modelo será capaz de identificar las placas vehiculares de automóviles a través de imágenes capturadas en los potenciales videos de seguridad o de vehículos (cámara de tablero). Adicionalmente, se utilizará OCR (Optical Character Recognition) para extraer el contenido de la placa. Esto facilitará la visualización y detección de placas para posibles investigaciones policiales.

**Keywords**—Reconocimiento de placas, seguridad, seguimiento de vehículos, redes neuronales.

## I. INTRODUCCIÓN

El transporte vehicular brinda numerosas ventajas a los usuarios. No obstante, las ventajas que estás ofrecen también pueden ser aprovechadas para actividades delincuenciales. Específicamente en Perú, surgen a diario noticias y reportajes sobre asaltos que utilizan una variedad de medios vehiculares para quebrantar la tranquilidad y reglas. Autos y motos, pueden y son aprovechados para provocar un ambiente inseguro en Perú. La relevancia del problema se ve reflejada en el Decreto Supremo N° 022-2019-IN, que busca fortalecer la seguridad ciudadana en materia de transporte, haciendo que conductores y pasajeros de motos tengan impreso en su casco y un chaleco los números de placa del vehículo. Además varios distritos propusieron la prohibición de motocicletas con más de un ocupante con el objetivo de combatir su uso para fines delincuenciales. Dicho esto, los vehículos generan tanto un impacto positivo como negativo dependiendo de quien los opera y el uso que se les da.

En este paper, se propone entrenar una red neuronal pre-entrenada para que sea capaz de

identificar placas vehiculares. Utilizar este tipo de red nos es útil ya que nos permite utilizar la estructura y aprendizaje de un modelo ya especializado en la detección de objetos. A diferencia de empezar con una red desde cero. El objetivo es facilitar y agilizar el seguimiento de vehículos buscados por las autoridades. Utilizando conocimiento sobre redes neuronales y técnicas de procesamiento de imágenes se entrenará el modelo para que pueda realizar el reconocimiento y la identificación de una o varias placas en una imagen, un OCR (Optical Character Recognition) se podrá extraer el contenido de la placa identificada en la imagen a datos. El detalle de la implementación y validación de la propuesta se documentará en las secciones IV y V.

Consideramos que el desarrollo de este tipo de software no presenta un dilema ético. Debido a que aquellos que aprovechan la propuesta, son aquellos que ya tienen acceso a esta información, los policías. El uso sería exclusivamente para ellos, por lo que solo implica la automatización de su trabajo.

## II. ESTADO DEL ARTE

### A. Propuestas con Redes neuronales

Para el desarrollo de la propuesta es importante aprender y conocer sobre proyectos similares hechos previamente en este campo. Papers relacionados al reconocimiento de placas vehiculares existen desde hace muchos años, por ejemplo el paper, *Car Plate Recognition by neural networks and image processing* (R. Parisi, E. D. Di Claudio, G. Lucarelli y G. Orlandi, 1998) [18]. En el cual se entrenó a una FNN. Los resultados fueron favorables teniendo un 90% de reconocimientos exitosos en un set de validación de 50 imágenes reales (8% lecturas fallidas y 2% erróneas). Además, un 98.7% de éxito al identificar caracteres, fallando al leer placas antiguas y oxidadas.

Otro trabajo relacionado es, *Using synthetic images for deep learning recognition process on Automatic License Plate Recognition* (S.

C. Barreto, J. A. Lambert, F. B. Vidal, MCPR 2019) [19]. En este caso, se puso a prueba la efectividad de identificación de una red neuronal entrenada con placas reales versus una red re-entrenada con placas sintéticas. Tras someter a pruebas a múltiples tipos de redes, se concluyó que redes neuronales previamente entrenadas para identificar otros objetos pueden usarse como punto inicial para el entrenamiento específico de un objeto. Además, se descubrió que las bases de datos sintéticas pueden mejorar el rendimiento en algunas de las etapas del entrenamiento.

Agregando a lo anterior, el paper *OCR On-the-Go: Robust End-to-end Systems for Reading License Plates & Street Signs* (R. Saluja, A. Maheshwari, G. Ramakrishnan, P. Chaudhuri y M. Carman, ICDAR 2019) [19], propuso solucionar una de las grandes dificultades del reconocimiento de placas. Siendo estas las difíciles condiciones bajo las cuales se realiza el análisis: el tráfico, lluvia, el tiempo del día, etc. Para este caso con el uso de variedad de datos (sintética limpia y real con ruido) para ejercer un entrenamiento riguroso. Se utilizó un modelo *baseline*, que consiste de una RNC como codificador y un RNR para decodificar la data necesaria. Los resultados obtenidos a partir de la investigación fueron exitosos teniendo un mejor rendimiento que otros métodos del momento (2019), mostrando un incremento de precisión con los datasets FSNS y IIIT-ILST Devanagari (1.1% y 8.19%, respectivamente).

Siguiendo con los modelos a seguir, tenemos uno siendo implementado en China. Las restricciones como la oscuridad, el brillo intenso, las rotaciones de los vehículos tratan de ser reducidas con la implementación del modelo. En el paper *A Robust License Plate Recognition Model Based on Bi-LSTM* (Y. Zou et al, 2020) [22], obtenemos el dato de los métodos de implementación del sistema junto a su probabilidad de reconocimiento. Con su investigación, junto a la inspiración de MobileNetV3 y Xception, se obtuvo un efectivo reconocimiento de las imágenes cercanas de placas. Este sistema pasó las pruebas de testeó con escenarios como: imágenes oscuras, rotadas, mal enfocadas y mucho brillo. Y cada una de ellas pasó satisfactoriamente con más del 90% de precisión. Por lo que esta propuesta es un ejemplo para el desarrollo del proyecto planteado.

Otro paper importante en nuestra investigación, es el que se detalla en: *A light CNN for End-to-End Car License Plates Detection and Recognition* (W. Wang, J. Yang, M. Chen y P. Wang. 2019) [21]. El reconocimiento de placas vehiculares es importante debido a su amplia gama de aplicaciones como seguridad ciudadana. El

método propuesto consiste en entrenar una red convolucional multitarea (MTCNN) y luego implementar un método de reconocimiento de extremo a extremo para un resultado eficiente. Para mejorar su rendimiento se usaron datos de placas en China con lo cual el rendimiento mejoró. Aún hay dificultades como iluminación, distorsión o desenfoque de caracteres debido al clima, sin embargo, el resultado experimental muestra que el método alcanza hasta un 98% de precisión en las pruebas y es superior tanto en precisión como en la velocidad de reconocimiento comparado con otros métodos de última generación.

El paper *Vehicle License Plate Detector in Compressed Domain* (M. S. Beratoğlu y B. U. Töreyn, 2021) [16], nos brinda información extra para apoyarse en los métodos e implementar la detección de imágenes en las placas de los vehículos. En este detalla que se hace uso del High Efficiency Video Coding, para la compresión de videos que permite investigar a fondo la data codificada. Además, se hace mención de algoritmos como Edge detection, Gabor filters, SIFT y análisis de componentes; Sin embargo, con el avance del deep learning, un nuevo algoritmo ha aparecido. CNN es usado para la detección de placas, brindando una precisión bastante alta al momento de la detección el cual llega hasta 98.22% en placas de carros de Taiwán. Mediante su uso se ha realizado un sistema de reconocimiento basado en el detector de objetos YOLO, el cual reportó una precisión de 99.51% llegando a obtener uno de los mejores resultados para la detección de placas.

Otro paper acerca del reconocimiento de placas vehiculares es el que se detalla en: *Automatic Vehicle License Plate Recognition Using Optimal K-Means With Convolutional Neural Network for Intelligent Transportation Systems* (I.V. Pustokhina, 2020) [8]. Los autores nos demuestran cómo resolver el desafío que representa el reconocimiento de las placas de los carros debido a las variaciones y obstáculos como la iluminación no uniforme. En el paper se detalla un reconocimiento de placas de vehículos eficaz basado en deep learning y utilizando segmentación basada en clusters óptimos del algoritmo K-Means y redes neuronales convolucionales (CNN). La solución consiste en 3 fases: La detección de placas de vehículos, la segmentación mediante la agrupación del algoritmo K-Means y finalmente el reconocimiento de las placas usando redes neuronales convolucionales. Este modelo se puede emplear como pilar importante en infraestructuras inteligentes de ciudades como el cobro de tarifas de peaje, gestión de aparcamientos y seguridad ciudadana. En el experimento realizado en 2019 se alcanzó una precisión de placas reconocidas en un 0.981 el cual está por encima del promedio.

### B. Otras propuestas (procesamiento de imágenes, algoritmos genéticos, etc)

Entre propuestas que se diferencian de las demás por su enfoque está *Car Plate Recognition Using the Template Matching Method* (M.I.Khalil, 2010) [14], el cual trató de innovar sobre el método tradicional que involucra una etapa de segmentación de caracteres como algunas propuestas anteriores. En este caso, se aplicó la técnica “*The moving window with template matching method*”. Este método extrae el nombre del país y caracteres de la placa, comparándolos con datos de una base de datos. De esa manera, se identifica al país de la placa y su código cuando el resultado de la comparación es coincidente. Este enfoque también demostró ser viable con un 90% de precisión, requiriendo alrededor de 1.6 segundos para identificar la placa. La única desventaja es que se aplicó sólo para Egipto y Arabia Saudita.

En este sentido, en el paper *A robust Deep Learning Approach for Automatic Iranian Vehicle License Plate Detection and Recognition for Surveillance Systems* (A. Tourani, A. Shahbahrani y S. Soroori, 2020) [1]. Se propuso una detección unificada de placas vehiculares del país de Irán mediante la unificación de caracteres y su sistema de reconocimiento usando redes secuenciales YOLO v.3. El sistema fue entrenado con datos en condición realistas en diversas de condiciones climáticas de ruido o iluminación recopilados de cámaras de vigilancia. Esta propuesta tuvo resultados de 0.979 y 0.991, el cual funciona en tiempo real con casi 119.73 milisegundos por imagen. Asimismo, usando el reconocimiento de placas mediante caracteres unificados se tiene una ventaja multinacional [3] Este tipo de algoritmo es simple pero extrae la secuencia correcta del número de la placa de una imagen. Este reconocimiento se ha probado con placas de más de 17 países como Taiwán, EE.UU, Grecia y Croacia el cual demora solo 42 ms por imagen. Esto demuestra que tiene la ventaja de ser compatible con conjunto de datos de varios países sin necesidad de algoritmos adicionales o la información del país.

Es necesario tener conceptos generales de las tecnologías de reconocimiento de imágenes. Por ello, el paper *Image Recognition Technology Based on Machine Learning* (L. Liu, Y. Wang y W. Chi, 2020) [13] nos brindará el desarrollo y las tecnologías existentes para el tema de reconocimiento de imágenes, todo ello basado en Machine Learning. En este método, las características más importantes de la imagen son separadas por lo que el reconocimiento puede ser aplicado para varias industrias. Por ello, varios sistemas de proceso de imágenes que usan machine

learning brindan la opción de clasificación de imagen, reconocimiento y segmentación. Además, el paper brinda el ejemplo de reconocimiento de vehículos con el uso de sistemas implementados con Machine Learning el cual es del mismo campo al proyecto a desarrollar.

En el paper *Detection and Evaluation Method of Transmission Line Defects Based on Deep Learning* (H. Liang, C. Zuo y W. Wei, 2020) [6] tenemos la información del desarrollo, costos y recursos usados para la realización del sistema de detección de líneas de transmisión. Al momento de su desarrollo, se presentaron problemas como imágenes pequeñas, no nítidas o factores de iluminación, esto no permite obtener información suficiente para que el software tenga un resultado eficiente. Sin embargo, con la aplicación de los algoritmos de deep learning permitieron no solo detectar las imágenes aéreas, sino también diferenciar los colores de forma nítida y representar sus características. El aumento de métodos que apoyen al sistema principal permitió llenar los huecos que dejaban los problemas encontrados en cada detección de imágenes. Por lo que se puede concluir que podemos hacer uso de más de un método con tal de evitar errores para que el proyecto siga en pie de forma eficiente.

Con el propósito de tener un mejor entendimiento el funcionamiento del algoritmo genético usado para el reconocimiento de placas de vehículos automáticos tenemos el paper *Corrections to Toward an Optimized Neutrosophic k-Means With Genetic Algorithm for Automatic Vehicle License Plate Recognition (ONKM-AVLPR)* (B. B. Yousif, M. M. Ata, N. Fawzy y M. Obaya, 2021) [2], El cual describe el funcionamiento de algoritmos que pueden ser representados de forma matemática como variables de mínimos y máximos de cada parámetro, la cual permite al usuario entender mejor el funcionamiento y aprovecharlo para dar soluciones más eficientes. Cabe destacar que el algoritmo genético utilizado permite reconocer caracteres especiales y letras tanto en inglés como en arábico. Además, permite identificar las regiones de los píxeles conectados entre sí para extraer cada carácter de forma efectiva.

### C. Principios de la Ética para la Inteligencia Artificial

Por último, cabe mencionar los principios éticos de la inteligencia artificial. Según lo que se dice en *The Role and Limits of Principles in AI Ethics: Towards a Focus on Tensions* (J. Whittlestone, R. Nyrop, A. Alexandrova, and S. Cave, 2019) [9], existen acuerdos en la comunidad para combatir las dificultades más notorios como la

imparcialidad y el sentido de justicia. Teniendo en cuenta esto, múltiples organizaciones han emitido conjuntos de principios tratando de conseguir que sean difundidos. No obstante, este surgimiento de variedades de principios están destinadas a ser redundantes. Por lo que [10], sugirió que todo puede ser resumido en principios ya aplicados a la bioética: autonomía, beneficencia, no-maleficencia y justicia. Más explicabilidad, para el caso de la inteligencia artificial. Dicho eso, se busca realizar un trabajo que cumpla con estos principios. Se tiene como objetivo que sea una propuesta que aporte un avance para la solución de la problemática y sea transparente, es decir, sin motivos ocultos más que los mencionados previamente.

### III. APOORTE

Para el desarrollo de la propuesta se utilizará y se va a implementar una Red Neuronal Convolutiva en Python, con la librería Detecto. Específicamente, RestNet50, que se especializa en detección de objetos. La cual cuenta con decenas de capas. Precisamente, como dice su nombre 50 capas.

Para el entrenamiento, se va a utilizar un dataset publicado en *Kaggle* llamado, Car License Plate Detection [12], y otro extraído de github [17], que contiene imágenes de Rumania, con varianza en iluminación y ruido. Consiste en archivos con los formatos .xml y .png. Los archivos .png [Fig.1] son imágenes de carros, con la placa visible y los .xml [Fig.2] tienen información relacionada a la posición de la placa en cada foto y la etiqueta asociada a esa placa. Para nuestro caso, solo se identificarán placas por lo que es la única etiqueta del dataset. Este conjunto de datos es de utilidad para tanto validación o entrenamiento de la red de ser necesario. El modelo recibirá como entrada una imagen de un carro que muestra su placa. La salida será un conjunto de coordenadas, que conforman un rectángulo. Dicho rectángulo es la predicción, es decir, locación de la placa según el modelo.



Fig. 1. una de las fotos del dataset de entrenamiento

```
<annotation>
  <folder>images</folder>
  <filename>Cars0.png</filename>
  <size>
    <width>500</width>
    <height>268</height>
    <depth>3</depth>
  </size>
  <segmented>0</segmented>
  <object>
    <name>licence</name>
    <pose>Unspecified</pose>
    <truncated>0</truncated>
    <occluded>0</occluded>
    <difficult>0</difficult>
    <bndbox>
      <xmin>226</xmin>
      <ymin>125</ymin>
      <xmax>419</xmax>
      <ymax>173</ymax>
    </bndbox>
  </object>
</annotation>
```

Fig. 2. archivo .xml del dataset con las coordenadas y etiqueta de la placa [Fig. 1]

Para implementar lo mencionado previamente se utilizará la herramienta de google colab en la cual primero se deberán realizar las instalaciones e importaciones de las librerías a utilizar. Entre ellas están: *Detecto*, *Matplotlib*, *Cv2* y *skimage*. Una vez hecho eso se tiene que cargar el dataset [12] con las imágenes y archivos .xml. Posteriormente, se cargará uno de los modelos pre-entrenados y se hará el entrenamiento con nuestro dataset. Luego, tras el entrenamiento se podrá hacer predicciones sobre imágenes de prueba y validar la efectividad de la detección de placas.

Al comprobar la capacidad de detección del modelo, se le aplicarán técnicas de procesamiento de datos a las imágenes. Con el objetivo de extraer la placa detectada. Para que, con la ayuda de la librería *easyocr*, se extraerá el contenido textual y numérico, de la placa. El detalle de todo este proceso se encuentra en las secciones IV y V.

### IV. DISEÑO DEL APLICATIVO

Inicialmente, se procedió a re-entrenar el modelo de ResNet50 con nuestra propia data para la detección de placas. Teniendo como único label "license-plate" y múltiples imágenes que varían en iluminación, ángulo y claridad. Se entrenó por siete épocas con cada uno de los datasets.




Fig. 3. Gráfico de precisión vs épocas, en el entrenamiento.

Tras el entrenamiento, ya es posible realizar predicciones con imágenes y extraer la imagen de la placa que se encuentre, si es que detecta alguna. Esto se evidencia a continuación:



Fig. 4. Detección de placa



Fig. 5. Extracción de placa.

Utilizando el atributo *box* que nos devuelve el modelo, es posible cortar la imagen según las coordenadas en las que se encuentra la placa.

El siguiente paso, involucra la aplicación de técnicas de procesamiento de imágenes para poder facilitar la interpretación de texto. La técnica implementada para esta ocasión, es la de thresholding. Inicialmente, se convierte la imagen a escala de grises con la librería *skimage* y se aplica el thresholding. Todos los píxeles con un valor menor a 100 se volverán negros, caso contrario, se vuelven blancos.



Fig. 6. Placa en escala de grises.




Fig. 7. Aplicación de Thresholding.

Finalmente, tras todo este proceso se puede pasar a utilizar el OCR. Los resultados se explicarán en detalle en la siguiente sección, V.

## V. VALIDACIÓN DE RESULTADOS Y DISCUSIÓN

La detección de las placas es influenciada por múltiples factores. Sea la iluminación, resolución, distancia cámara-placa y ángulo de visión. En nuestros resultados, hemos notado que los factores mencionados son mucho más relevantes para la extracción de texto que la detección de la placa. Debido a la distorsión del texto cuando la imagen está muy lejos, en un ángulo complicado, o ambos.

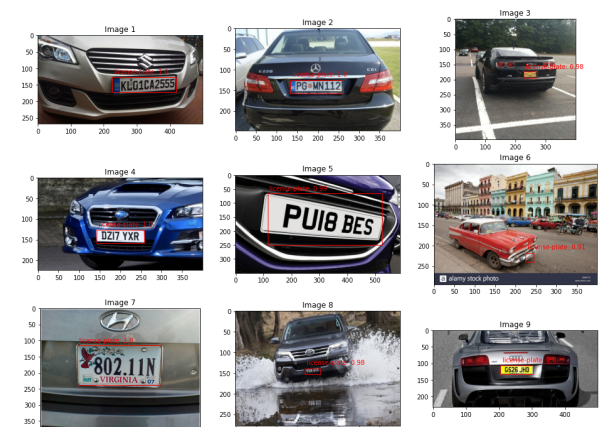


Fig. 8. Predicción en 9 imágenes con ángulos y distancias mayormente favorables.

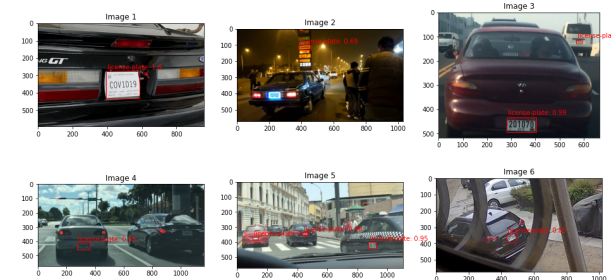


Fig. 9. Predicción en 6 imágenes con una mayor varianza en distancia, iluminación y ángulo de visión.

Como se puede observar en todos los casos la detección exitosa de placas, con la excepción de la imagen dos en la Figura 9. Debido a que la placa tiene luces neón. No obstante demuestra la alta precisión del modelo para detectar placas.

En cuanto a la detección de texto, la precisión se ve mucho más afectada por los factores mencionados previamente, Tabla 1 y 2.

Imagen	Placa	Resultado
1	KLO1CA2555	KLo1CA2555
2	PG MN112	PGoMN112
3		EIV
4	DZI7 YXR	DZI7 YXR
5	PUI8 BES	Pui8_BES
6		-
7	802.11N	802 LIN
8	YSX 213	Ysx2/3
9	G526 JHD	6526 JhD

Tabla 1. Contenido de placas y texto extraído de imágenes de Figura 8.

Imagen	Placa	Resultado
1	COVID19	CoV1d1g
2	C12 627	-
3	201070	12jt
4	356 KM2	-
5	ANC 031	-
6	BET 256	-

Tabla 2. Extracción de texto en imágenes más ruidosas de Figura 9.

Como se especificó y se demuestra en los resultados de las tablas 1 y 2, la precisión de la extracción de texto disminuye considerablemente con imágenes con placas no muy nítidas, lejanas y/o que estén de costado.

## VI. CONCLUSIONES Y TRABAJOS EN FUTURO

Hemos encontrado algunas limitaciones a tomar en consideración al momento de seleccionar las imágenes para el reconocimiento de las placas vehiculares, estas restricciones son las siguientes:

1. El modelo sólo lee archivos de imágenes con formatos .png y .jpg.

2. La detección de texto sólo reconoce placas con letras y símbolos inglés estándar.
3. Si la placa de vehículo de la imagen a procesar se encuentra a una distancia considerable, no se podrá llegar a detectar de forma efectiva el texto de la placa.
4. Si existen interferencias en la imagen, como luz neón, la placa no es detectada fácilmente. Por ejemplo, en casos particulares, algunos propietarios de vehículos ponen luces neón al contorno de la placa para que ésta luzca más llamativa (Imagen 2, Fig. 9). Esto al generar un brillo o iluminación irregular en la imagen captada dificulta la identificación del texto de la placa.
5. Existen complicaciones en la detección de texto de la placa con imágenes sin mucha resolución o placas que se encuentren en ángulos extraños.

Por lo que recomendamos en un trabajo a futuro mejorar las limitaciones mencionadas anteriormente. Específicamente, para lidiar con placas lejanas o imágenes de poca calidad la aplicación de un filtro que reduzca el ruido podría ser de utilidad. Adicionalmente se recomienda la implementación de funcionalidades como la mejora de calidad de imagen, la implementación del lector de formatos de imagen .gif y .tiff.

Dejando de lado las limitaciones y puntos de mejora, la implementación de un modelo capaz de reconocer placas fue satisfactoria. De similar manera, la extracción de contenido obtuvo variados resultados, sin embargo, es un positivo punto de mejora por si se retoma el proyecto en el futuro. El desarrollo o uso de otros OCR podría ser evaluado. Tal vez, consiguiendo mejores o peores resultados que los del paper en cuestión. Teniendo en cuenta el estado actual del proyecto, su uso ideal sería en cámaras de tablero. Donde, por ejemplo, un carro policial podría detectar automáticamente las placas de los carros que tenga directamente enfrente. Debido a la cercanía entre los carros, el ángulo y la distancia serían los ideales para que nuestra propuesta detecte y extraiga la información de la placa.

Un aspecto que podría diferenciar este proyecto del resto, especialmente en nuestro contexto. Es que el modelo sea capaz de reconocer placas que contengan una alta cantidad de personalización. Específicamente en Perú, dependiendo de la zona no es inusual ver placas vehiculares con luces de neón, adornos en los bordes y tipografía especial. Sin embargo, para ello la recolección de una base de datos enfocada para ese tipo de placas sería necesaria. Lo cual podría



ser un reto interesante para poder implementar como trabajo a futuro.

## VII. REFERENCIAS BIBLIOGRÁFICAS

- [1] A. Tourani, A. Shahbahrami, S. Soroori, S. Khazaei y C. Y. Suen, "A Robust Deep Learning Approach for Automatic Iranian Vehicle License Plate Detection and Recognition for Surveillance Systems", IEEE Access, vol. 8, pp. 201317-201330, 2020.
- [2] B. B. Yousif, M. M. Ata, N. Fawzy and M. Obaya, "Corrections to "Toward an Optimized Neutrosophic k-Means With Genetic Algorithm for Automatic Vehicle License Plate Recognition (ONKM-AVLPR)"", IEEE Access, vol. 9, pp. 39411-39412, 2021.
- [3] C. Henry, S. Y. Ahn and S. -W. Lee, "Multinational License Plate Recognition Using Generalized Character Sequence Detection", IEEE Access, vol. 8, pp. 35185-35199, 2020.
- [4] Congreso del Perú (2017). Proyecto de Ley 01696/2016-CR. Grupo Parlamentario "Fuerza Popular". Recuperado de: [https://www2.congreso.gob.pe/sicr/tradocestproc/CL\\_ProLey2016.nsf/Parlamentarios/496F63DFE4EB092B05258164007D5B04?opendocument](https://www2.congreso.gob.pe/sicr/tradocestproc/CL_ProLey2016.nsf/Parlamentarios/496F63DFE4EB092B05258164007D5B04?opendocument)
- [5] Diario Gestión (02 de diciembre de 2021). "¿Qué debe hacer si desea renunciar al subsidio del Estado?". Bono Yanapay Perú. Recuperado de: <https://gestion.pe/peru/bono-yanapay-peru-bono-350-bono-yanapay-peru-que-debe-hacer-si-desea-renunciar-al-subsidio-del-estado-midis-ndc-noticia>
- [6] H. Liang, C. Zuo and W. Wei, "Detection and Evaluation Method of Transmission Line Defects Based on Deep Learning", IEEE Access, vol. 8, pp. 38448-38458, 2020.
- [7] H. Seibel, S. Goldenstein and A. Rocha, "Eyes on the Target: Super-Resolution and License-Plate Recognition in Low-Quality Surveillance Videos", IEEE Access, vol. 5, pp. 20020-20035, 2017.
- [8] I. V. Pustokhina et al., "Automatic Vehicle License Plate Recognition Using Optimal K-Means With Convolutional Neural Network for Intelligent Transportation Systems", IEEE Access, vol. 8, pp. 92907-92917, 2020.
- [9] Jess Whittlestone, Rune Nyrupe, Anna Alexandrova, and Stephen Cave. 2019. "The Role and Limits of Principles in AI Ethics: Towards a Focus on Tensions", Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society (AI/ES '19). Association for Computing Machinery, New York, NY, USA, 195-200.
- [10] Josh Cowls and Luciano Floridi. 2018. Prolegomena to a White Paper on an Ethical Framework for a Good AI Society. (2018).
- [11] J. Shashirangana, H. Padmasiri, D. Meedeniya and C. Perera, "Automated License Plate Recognition: A Survey on Methods and Techniques", IEEE Access, vol. 9, pp. 11203-11225, 2021.
- [12] Larxcel, (31/05/2020) "Car License Plate Detection", Kaggle Dataset. Recuperado de: <https://www.kaggle.com/andrewmvd/car-plate-detection>
- [13] L. Liu, Y. Wang and W. Chi, "Image Recognition Technology Based on Machine Learning", IEEE Access.
- [14] M.I.Khalil, "Car Plate Recognition Using the Template Matching Method", International Journal of Computer Theory and Engineering, vol. 2, No. 5, 2010.
- [15] M. S. Al-Shemarry and Y. Li, "Developing Learning-Based Preprocessing Methods for Detecting Complicated Vehicle Licence Plates", IEEE Access, vol. 8, pp. 170951-170966, 2020.
- [16] M. S. Beratoğlu and B. U. Töreyn, "Vehicle License Plate Detector in Compressed Domain", IEEE Access, vol. 9, pp. 95087-95096, 2021.
- [17] RobertLucian. (21/01/2020) "license-plate-dataset". Repositorio de Github. Recuperado de: <https://github.com/RobertLucian/license-plate-dataset>
- [18] R. Parisi, E. D. Di Claudio, G. Lucarelli and G. Orlandi, "Car plate recognition by neural networks and image processing", IEEE International Symposium on Circuits and Systems (ISCAS), 1998.
- [19] R. Saluja, A. Maheshwari, G. Ramakrishnan, P. Chaudhuri and M. Carman, "OCR On-the-Go: Robust End-to-End Systems for Reading License Plates & Street Signs," 2019 International Conference on Document Analysis and Recognition (ICDAR), 2019, pp. 154-159, doi: 10.1109/ICDAR.2019.00033.
- [20] S. C. Barreto, J. A. Lambert, F. B. Vidal, "Using synthetic images for deep learning recognition process on Automatic License Plate Recognition", MCPR 2019 (Mexican conference on pattern recognition).
- [21] W. Wang, J. Yang, M. Chen and P. Wang, "A Light CNN for End-to-End Car License Plates Detection and Recognition", IEEE Access, vol. 7, pp. 173875-173883, 2019.
- [22] W. Weihong and T. Jiaoyang, "Research on License Plate Recognition Algorithms Based on Deep Learning in Complex Environment", IEEE Access, vol. 8, pp. 91661-91675, 2020.
- [23] Y. Zou et al., "A Robust License Plate Recognition Model Based on Bi-LSTM", IEEE Access, vol. 8, pp. 211630-211641, 2020.
- [24] Z. Tomas, C. Moran S, D. Napuri (2019), "Decreto Supremo N° 022-2019-IN". Recuperado de: <https://www.gob.pe/institucion/mininter/normas-legales/322989-022-2019-in>